

Applying Image-based Asset Pricing Models

고종한, 장한이, 조해윤, 황교선

2026.05.02

Image-based Asset Pricing Models

- **문제**
 - Handcrafted / Predefined signals (Momentum, Reversal 등) → 정보 손실 + 제한된 패턴
 - Low signal quality → Low rank correlation → High inter-model correlation
- **접근**
 - Raw price path(OHLCV) 사용 → Image / Sequence
 - Feature engineering 제거 → 모델이 Pattern 직접 학습
 - Multi-model framework → CNN, LSTM, logistic
- **핵심 가설**
 - 가격 경로는 단순 숫자보다 Richer Signal 포함
 - Model 보다 Representation 자체가 성능을 결정

Modeling Framework

- **Input: 60-day OHLCV window**

- **Model**

- Logistic (baseline)
- CNN-based(1D, 2D)
- LSTM(Sequence based)
- Hybrid(CNN + LSTM)

Family	모델 수	비고
Logistic Baseline	2	image / cumulative
CNN 1D	4	image / dilated / attention / multiscale
CNN 2D	3	rendered / residual / small
LSTM	2	image / cumulative
CNN + LSTM Hybrid	2	image / cumulative
합계	14	동일 walk-forward grid에서 비교

표1. 모델 정리

- **Output**

- Cross-sectional signal → Ranking score

- **Evaluation**

- Signal quality → Spearman rank correlation
- Portfolio performance → Top-k Sharpe

Data Representation

- **Input Construction**

- 60-day OHLCV window → rolling window로 생성60일
- Chart-based rendering → 2D grayscale image

- **Encoding**

- Price series → line / path 형태로 표현
- Volume → 하단 intensity (bar 형태)
- 전체 window → 하나의 이미지로 압축

- **이미지 기반 표현을 통해 패턴을 직접 학습**

- Price shape (trajectory / curvature)
- Relative position (local high / low)
- Temporal pattern (trend / reversal)




그림. 60-day OHLCV encoded as 2D grayscale chart images

Model & Evaluation Overview

- **Model**
 - Logistic / CNN / LSTM / Hybrid (총 14개)
- **Data**
 - Lookback = 60
 - Horizon = 20
- **Evaluation**
 - Walk-forward expanding
 - Rank corr / Top-k Sharpe

Model-level Performance

- 단일 모델 간 성능 차이는 크지 않음
- **Observation**
 - ensemble_4family: rank corr 0.0674 로 최고
 - ensemble_best: Sharpe 0.643으로 최고
 - best rank corr $\approx 0.04 \sim 0.06$ 수준
 - 모델만으로 큰 차이 만들기 어려움
- **Implication**
 - 단일 모델 성능 차이는 제한적
 - Representation 및 Ensemble이 성능 차이를 결정




그림. OOS rank correlation and top-k Sharpe comparison

Representation vs Model

- **Logistic**
 - no image: -0.007
 - image: +0.039 → 약 +0.046 lift
- **CNN**
 - no image: +0.027
 - image: +0.028 → 추가 lift는 거의 없음
- **Implication**
 - CNN 자체 성능보다 representation 효과가 큼
 - image transform이 주요 기여




그림. Image transform vs CNN contribution ablation

Signal Correlation Structure

- CNN-CNN 상관계수: ~0.5~0.6 (높음)
- LSTM-CNN: 낮은 상관계수
- 일부 모델은 음의 상관
 - cnnlstm_image - logistic_image 약 -0.17
- 해석
 - 모델 Family 간 다양성 존재
 - Low correlation → Ensemble에 유리
 - 단독 성능보다 ensemble 기여도가 더 중요




그림. Raw-signal correlation matrix across model families

Ensemble Improves Performance

- **Phase 1 (CNN only)**
 - rank corr ≈ 0.038 / Sharpe ≈ 0.275
- **Phase 3 (logistic + CNN):**
 - rank corr ≈ 0.060 / Sharpe ≈ 0.64
- **Phase 4 (+ LSTM):**
 - rank corr 0.0674 / Sharpe 0.543
 - rank corr 증가 / Sharpe 일부 감소
- **결론**
 - Rank corr는 증가했지만 Sharpe는 trade-off 존재
 - Ensemble이 성능 개선에 기여
 - Model diversity가 성능 개선에 기여

Lift progression — single → 3-family → 4-family ensemble




그림. Rank corr and Sharpe changes across ensemble phases

Significance of Improvements

- **Bootstrap CI:**
 - ensemble_4family - ensemble_best
 - ensemble lift $\approx +0.0068$
 - CI: $[-0.0024, +0.0157]$

- **해석**

- 통계적 유의성은 약함
- Improvement 방향은 일관

- **의미**

- mechanism evidence가 일관
- 일관된 개선 경향 존재 (but not statistically strong)




그림. Paired bootstrap confidence interval for ensemble lift

Conclusion

- **주요 분석 결과**
 - Representation 효과가 성능에 크게 기여 → image transform이 핵심 기여
 - Ensemble이 single model 대비 성능 개선 경향 → diversification 효과
 - Model family 다양성 중요 → correlation 구조가 ensemble 성능에 중요한 역할
- **의의**
 - 가격 경로 기반 signal 생성 가능성 확인
 - image representation의 실질적 성능 기여 확인
 - model diversity 기반 ensemble 필요성 확인
- **향후 분석**
 - signal → portfolio allocation으로 확장
 - model별 dynamic weighting / optimization